Homotopía, Redes Neuronales y la Ecuación Fundamental de la Inteligencia Artificial

Apunte de investigación — Abril 2026

Rodolfo H. Rodrigo
INAUT, Universidad Nacional de San Juan – CONICET
San Juan, Argentina
rrodrigo@inaut.unsj.edu.ar

Abstract

Este apunte sintetiza una visión unificada del aprendizaje automático basada en la ecuación de deformación de Liao (Método de Análisis Homotópico, HAM). La tesis central es que *toda red neuronal es un operador no lineal*, y que la ecuación de Liao $(1-q)\,\mathcal{L}[\phi-\phi_0] = q\,c_0\,\mathcal{N}[\phi]$ constituye la *ecuación constitutiva* faltante de la IA: determina los coeficientes de la red por deformación (no por optimización), cuantifica cuántas neuronas y cuántos datos se necesitan, y formaliza cómo el conocimiento previo—codificado en $\mathcal{L}$—reduce el tamaño de la red. Cuando $\mathcal{L}$ es reemplazado por una red neuronal ya entrenada, emerge un mecanismo de *aprendizaje incremental convergente*: cada iteración agrega conocimiento y reduce el residuo, con redes progresivamente más pequeñas. El documento integra resultados teóricos, experimentales y conexiones con métodos existentes (PINN, boosting, ResNets, transfer learning).

Contents

1 La observación fundamental **3**

2 El aprendizaje como deformación, no como optimización **3**

3 Estructura bilineal: todas las redes son iguales **4**

4 Tres niveles de homotopía para un mismo sistema **4**

5 Dimensionamiento constructivo: ¿cuántas neuronas, cuántos datos? **5**
5.1 Verificación numérica: flujo por orificio 6

6 El conocimiento previo como operador $\mathcal{L}$ **6**
6.1 Comparación con PINN 7

7 $\mathcal{L}$ como red neuronal: aprendizaje incremental **7**
7.1 El proceso iterativo 7
7.2 Qué formaliza esto 8

8 ANN como sucedáneo de la física: problemas inversos **8**
8.1 Experimento: raíces de polinomios vía relaciones de Vieta 8
8.2 ¿Por qué no entrenar directamente una ANN inversa? 9

9 La elección de $\mathcal{L}$ como inductive bias formal **9**

10 La matemática formal que le falta a la IA **10**

11 Síntesis: un solo framework para toda la IA **10**

12 Conclusiones y líneas abiertas **11**
12.1 Líneas abiertas 11

1 La observación fundamental

Idea clave

Una red neuronal artificial (ANN) es un operador no lineal $\mathcal{N} : \mathbb{R}^n \to \mathbb{R}^m$ parametrizado por $\boldsymbol{\theta}$. No importa su arquitectura (RBF, MLP, CNN, LSTM, Transformer): todas son funciones no lineales de sus entradas y sus parámetros.

La ecuación de deformación de Liao:

$$\boxed{(1-q)\,\mathcal{L}[\phi(q)-\phi_0] = q\,c_0\,\mathcal{N}[\phi(q)]} \tag{1}$$

resuelve $\mathcal{N}[\phi] = 0$ para *cualquier* operador no lineal $\mathcal{N}$, deformando continuamente desde una solución conocida ϕ_0 (en $q = 0$) hasta la solución buscada (en $q = 1$). Las correcciones:

$$z_1 = \gamma, \qquad z_2 = \gamma(1+\sigma), \qquad z_3 = \gamma(1+\sigma)^2 + \frac{c_0\,\mathcal{N}_0''}{2\lambda}\,\gamma^2 \tag{2}$$

con $\gamma = c_0\,\mathcal{N}_0/\lambda$ y $\sigma = c_0\,\mathcal{N}_0'/\lambda$, son **universales**: dependen solo del residuo ($\mathcal{N}_0$), el Jacobiano ($\mathcal{N}_0'$) y el Hessiano ($\mathcal{N}_0''$) del operador, no de su estructura interna.

Resultado

Si la ecuación de Liao aplica a cualquier operador no lineal, y una ANN es un operador no lineal, entonces la ecuación de Liao es la *ecuación constitutiva de las redes neuronales*. Juega para la IA el rol que $F = ma$ juega para la mecánica.

2 El aprendizaje como deformación, no como optimización

La práctica actual del deep learning está basada en **optimización**: backpropagation calcula el gradiente $\partial\mathcal{N}/\partial\boldsymbol{\theta}$ y da un paso de tamaño η (learning rate) en la dirección negativa del gradiente. Es una búsqueda: no sabe a dónde va, puede quedarse en mínimos locales, necesita miles de iteraciones, y no puede garantizar nada sobre el resultado.

La homotopía propone algo fundamentalmente distinto: **deformación**. No busca un mínimo — deforma continuamente desde lo conocido (ϕ_0) hasta lo necesario ($\mathcal{N}[\phi] = 0$). El camino está definido por la ecuación. Las correcciones z_1, z_2, z_3 son los pasos del camino. Y el camino existe y es único si $|1+\sigma| < 1$.

Table 1: Optimización vs. deformación.

Aspecto	**Backpropagation**	**Homotopía**
Mecanismo	Busca mínimo de $\|\mathcal{N}\|^2$	Deforma $\phi_0 \to \phi^*$
Dirección	No sabe a dónde va	Camino definido por (1)
Convergencia	Lineal ($O(1/k)$)	Cuadrática/cúbica (z_1/z_2)
Learning rate	Necesario, crítico	No existe (autoregulado por c_0)
Mínimos locales	Puede quedar atrapado	No hay landscape, hay deformación
Garantías	Ninguna a priori	$\|1+\sigma\| < 1$ es verificable

Los coeficientes de la red no se "optimizan". Se **determinan** por el proceso de deformación. Así como la trayectoria de un planeta no se optimiza — se determina por la ecuación de Newton — los parámetros de una red se determinan por la ecuación de Liao.

3 Estructura bilineal: todas las redes son iguales

Todas las arquitecturas neuronales comparten una estructura común: una **capa de salida lineal** en sus pesos, y **parámetros internos no lineales**. La homotopía explota esto universalmente.

Table 2: Arquitecturas neuronales como operadores no lineales con estructura bilineal.

Arquitectura	$\mathcal{N}[\phi]$	**Lineales**	**No lineales**
RBF	$\sum w_j\, \varphi(\|x - c_j\|/\lambda_j)$	w_j	$c_j,\ \lambda_j$
MLP	$W_2\, \sigma(W_1 x + b_1)$	W_2 (última capa)	$W_1,\ b_1$
CNN	$W_{\text{fc}} \cdot \text{conv}(x;\, \mathcal{K})$	W_{fc}	kernels $\mathcal{K}$
LSTM	$W_o \cdot h_T(x;\, W_h)$	W_o	$W_h,\ W_f,\ W_i$
SOM	$\sum w_j\, \eta(\|x - m_j\|)$	topología fija	prototipos m_j
Transformer	$W_{\text{head}} \cdot \text{attn}(x;\, Q, K, V)$	W_{head}	$Q,\ K,\ V$

Resultado

Para *cualquier* arquitectura: los pesos lineales (última capa) se resuelven exactamente con z_1 en un solo paso (mínimos cuadrados). Los parámetros no lineales (capas internas) se corrigen con z_1 (Newton), z_2 (Halley), z_3 (tercer orden). No hay backpropagation en ningún nivel.

4 Tres niveles de homotopía para un mismo sistema

Consideremos un sistema no lineal $\dot{y} + f(y) = u(t)$ donde f se modela con una RBF:

$$\hat{f}(y) = \sum_{j=1}^{M} w_j\, \varphi\left(\frac{\|y - c_j\|}{\lambda_j}\right)$$

Tres problemas clásicamente separados se unifican:

Table 3: Tres niveles, una ecuación.

Nivel	Problema	$\mathcal{L}$	$\mathcal{N}$	ϕ
1	Identificar RBF	I	$\Phi\mathbf{w} - \mathbf{f}$	$(\mathbf{w}, \mathbf{c}, \boldsymbol{\lambda})$
2	Simular ODE	$d/dt + k$	$\dot{y} + \tilde{f}(y) - u$	y_k
3	Ajuste online	I	error de tracking	$(\mathbf{c}, \boldsymbol{\lambda})$

Nivel 1 — Identificación: $\mathcal{N}$ es el error de aproximación de la RBF. Los pesos w_j se obtienen por mínimos cuadrados (z_1 exacto). Los centros c_j y anchos λ_j se corrigen por Newton–Halley. Inicialización: K-means.

Nivel 2 — Simulación: Partimos de la solución lineal conocida $y_0(t) = y_0\, e^{-kt} + \int_0^t e^{-k(t-s)} u(s)\, ds$ y deformamos hacia la solución no lineal. El residuo integral (sin $1/T$, sin derivadas numéricas) se corrige paso a paso con z_1, z_2, z_3.

Nivel 3 — Online: Las mismas fórmulas del Nivel 1 operan sobre una ventana deslizante de datos nuevos. La red se refina incrementalmente.

Idea clave

Las mismas fórmulas z_1, z_2, z_3 resuelven los tres problemas. Lo que cambia es qué significan $\mathcal{N}_0$, $\mathcal{N}_0'$, $\mathcal{N}_0''$ y λ.

5 Dimensionamiento constructivo: ¿cuántas neuronas, cuántos datos?

Esta es la pregunta abierta de Narendra y Parthasarathy (1990) que nadie respondió constructivamente. El teorema de aproximación universal (Cybenko 1989, Hornik 1991) dice que *existe* un M suficiente, pero no dice cuánto vale. Barron (1993) da $O(1/\sqrt{M})$ pero existencialmente.

El framework homotópico da la respuesta como una **cadena constructiva**:

$$\boxed{\varepsilon_{\text{sim}} \xrightarrow{\text{Gronwall}} \varepsilon_{\text{id}} \xrightarrow{\text{tasa RBF}} M_{\min} \xrightarrow{\text{cond}(J_c)} N_{\min} \xrightarrow{\text{convergencia}} T_{\max}} \tag{3}$$

Paso 1. Gronwall: $\varepsilon_{\text{id}} < \varepsilon_{\text{sim}} \cdot L/(e^{LT_f} - 1)$.

Paso 2. Tasa de aproximación RBF: $M \geq (b-a)\sqrt{C_\varphi K_2/\varepsilon_{\text{id}}}$.

Paso 3. Datos suficientes: $N \geq 3M$.

Paso 4. Paso temporal: $T < 1/\max|\tilde{f}'|$.

Resultado

Dado un error de simulación objetivo ε_{sim} y un horizonte T_f, la cadena (3) especifica *antes de entrenar*: cuántos centros (M), cuántos datos (N), y qué paso temporal (T). No hay trial-and-error sobre la arquitectura. Es la primera **ecuación de diseño** para redes

neuronales.

5.1 Verificación numérica: flujo por orificio

Sistema: $\dot{h} + 0.5\sqrt{h} = u(t)$, con $u(t)$ escalón-rampa, 20 puntos de datos, 5 centros Gaussianos.

Table 4: Resultados de la demo.

Métrica	**Valor**	**Criterio**
Error máx RBF vs real	2.3%	$< 5\%$ ✓
Error máx solución lineal	82%	—
Mejora RBF / lineal	35×	$> 3\times$ ✓
Centros utilizados	5	Teórico: 29 (equiesp.)
Datos de entrenamiento	20	Mínimo: 15

6 El conocimiento previo como operador $\mathcal{L}$

El $M_{\min}$ de la cadena (3) depende de $K_2 = \|\tilde{f}''\|_\infty$, la curvatura de la **no linealidad reducida** $\tilde{f} = f - \mathcal{L}^{-1}[f]$, no de f completa. El operador $\mathcal{L}$ codifica *lo que ya sabemos* del sistema. Lo que la red tiene que aprender es solo lo que falta: $\tilde{f}$.

Idea clave

Mejor conocimiento previo $\to$ mejor $\mathcal{L}$ $\to$ menor $\tilde{f}$ $\to$ menor $K_2(\tilde{f})$ $\to$ menos neuronas $\to$ menos datos. **Cuantificado.**

Table 5: Espectro de conocimiento previo.

Conocimiento	$\boldsymbol{\mathcal{L}}$	$\boldsymbol{\tilde{f}}$	$\boldsymbol{K_2}$	$\boldsymbol{M}$
Ninguno	I	f (todo)	Grande	Grande
Lineal	$d/dt + k$	$f(y) - ky$	Medio	Medio
Cuadrático	$d/dt + k + k_2 y$	$f - ky - k_2 y^2$	Chico	Chico
Modelo exacto	$\mathcal{L} = f$	$\tilde{f} = 0$	0	0
ANN previa	$\mathbf{ANN}_1$	$\boldsymbol{f - \mathbf{ANN}_1}$	**Decrece**	**Decrece**

La última fila es la clave: cuando $\mathcal{L}$ es reemplazado por una ANN ya entrenada, el framework se convierte en un mecanismo de **aprendizaje incremental**.

6.1 Comparación con PINN

Table 6: Dónde entra la física: PINN vs. homotopía.

Aspecto	**PINN**	**Homotopía**
La física entra en	Función de costo (penalidad)	Operador $\mathcal{L}$ (estructura)
Efecto sobre M	Ninguno (sigue trial-and-error)	Reduce M constructivamente
Convergencia	Descenso por gradiente (lineal)	Newton–Halley (cuadr./cúb.)
Dimensionamiento	No abordado	$\varepsilon \to M \to N$

Resultado

Poner la física en la función de costo (PINN) es agregar una *restricción*. Poner la física en el operador (homotopía) es *reducir el problema*. La restricción no cambia cuántas neuronas se necesitan; la reducción del operador sí.

7 $\mathcal{L}$ como red neuronal: aprendizaje incremental

Este es el resultado conceptual más profundo. Si $\mathcal{L}$ puede ser *cualquier operador lineal elegido libremente* (libertad fundamental del HAM), ¿qué pasa si elegimos $\mathcal{L} = \mathrm{ANN}_1$, una red ya entrenada?

La homotopía se convierte en:

$$(1-q)\,\mathrm{ANN}_1[\phi - \phi_0] = q\,c_0\,\mathcal{N}[\phi] \tag{4}$$

La ANN_2 que se entrena en esta iteración solo aprende el **residuo** $\tilde{f} = f - \mathrm{ANN}_1$. Y la cadena de dimensionamiento dice que ANN_2 puede ser más chica que ANN_1, porque $K_2(\tilde{f}) < K_2(f)$.

7.1 El proceso iterativo

Table 7: Aprendizaje incremental por homotopía.

Iter.	$\boldsymbol{\mathcal{L}}$	**La red aprende**	$\boldsymbol{K_2}$	$\boldsymbol{M}$
1	I (nada)	f completa	Grande	Grande
2	ANN_1	$\tilde{f}_1 = f - \mathrm{ANN}_1$	Medio	Medio
3	$\mathrm{ANN}_1 + \mathrm{ANN}_2$	$\tilde{f}_2 = f - \mathrm{ANN}_1 - \mathrm{ANN}_2$	Chico	Chico
k	$\sum_{i=1}^{k-1} \mathrm{ANN}_i$	$\tilde{f}_{k-1} \to 0$	$\to 0$	$\to 0$

Cada iteración:

1. El conocimiento acumulado crece.

2. El residuo se achica.
3. La red nueva es más chica.
4. La convergencia está garantizada si $|1+\sigma| < 1$ en cada paso.

Idea clave

El aprendizaje es **aditivo y convergente por construcción**. No hay olvido catastrófico, no hay inestabilidad. Cada red nueva solo tiene que aprender lo que las anteriores no cubrieron.

7.2 Qué formaliza esto

Boosting (Freund–Schapire): cada weak learner aprende el residuo del anterior. La homotopía le da la condición de convergencia ($|1+\sigma| < 1$) y el dimensionamiento (M_k decrece).

ResNets (He et al.): las skip connections hacen que cada bloque aprenda $\tilde{f} = f - \text{identidad}$. Eso es $\mathcal{L} = I$. La homotopía explica por qué funciona: el residuo tiene menor curvatura.

Transfer learning: el modelo preentrenado es $\mathcal{L}$. Fine-tuning es entrenar una red chica sobre $\tilde{f}$. La homotopía cuantifica cuánto más chica puede ser.

8 ANN como sucedáneo de la física: problemas inversos

Cuando la física forward es intratable analíticamente pero **medible experimentalmente** — multifísica, transferencia de calor acoplada con mecánica de fluidos, procesos químicos con cinética compleja — nadie tiene el operador $\mathcal{N}$ en forma cerrada. Pero sí tiene datos: mediciones de laboratorio, simulaciones FEM, ensayos experimentales.

Esquema propuesto:

1. Entrenar ANN_θ con pares (f_k, g_k) generados por medición/simulación: $\hat{\mathcal{N}}_\theta \approx \mathcal{N}$.
2. Invertir con HAM: dado g^* observado, resolver $\hat{\mathcal{N}}_\theta(f^*) = g^*$.

La homotopía para el problema inverso:

$$(1-q)\,\mathcal{L}[F(q) - f_0] = q\,c_0\,[\hat{\mathcal{N}}_\theta(F(q)) - g^*] \tag{5}$$

Las correcciones requieren $\mathcal{N}_0' = \partial\hat{\mathcal{N}}_\theta/\partial f\big|_{f_0}$ (Jacobiano de la ANN), que es **exacto por autodiff**.

8.1 Experimento: raíces de polinomios vía relaciones de Vieta

Forward (Vieta, física conocida): $(r_1, r_2, r_3) \mapsto (a_2, a_1, a_0)$

$$a_2 = -(r_1 + r_2 + r_3), \quad a_1 = r_1r_2 + r_1r_3 + r_2r_3, \quad a_0 = -r_1r_2r_3$$

Inverso (mal condicionado): dados coeficientes, hallar raíces.

Resultados clave:

- HAM+Vieta (física informada): converge exactamente.

- HAM+ANN (sucedáneo): converge al cero de la ANN, no de Vieta. Error acotado por la calidad del surrogate (~ 0.005).
- La columna ANN *replica* la columna Vieta fielmente. HAM hace su trabajo.
- Newton puro diverge (mal condicionamiento). Levenberg–Marquardt converge ($J^T J + \lambda I$ regulariza).

Idea clave

HAM converge siempre al inverso del operador que se le da. Si el operador es exacto (Vieta), la solución es exacta. Si es aproximado (ANN), la solución está acotada por el error del surrogate. **El error es del modelo, no del método.**

8.2 ¿Por qué no entrenar directamente una ANN inversa?

Porque las mediciones son pocas. Las pocas mediciones alcanzan para el forward porque es suave y bien condicionado. La inversa no: es mal condicionada, las pocas muestras no capturan la estructura de sensibilidad, y puede ser multivaluada. HAM extrae la inversión sin datos adicionales. **Los datos van al forward, HAM hace el resto.**

9 La elección de $\mathcal{L}$ como inductive bias formal

En machine learning se habla informalmente de "inductive bias": la arquitectura codifica supuestos sobre el problema. Una CNN asume invariancia traslacional. Un Transformer asume relevancia por atención. Pero nadie cuantifica el efecto del bias sobre el tamaño de la red.

En el framework homotópico, $\mathcal{L}$ *es* el inductive bias, y su efecto es cuantificable:

$$M \propto \|\tilde{f}\|_* = \|f - \mathcal{L}^{-1}[f]\|_* \tag{6}$$

donde $\|\cdot\|_*$ es la norma apropiada (K_2 para RBF, norma de Barron para MLP, etc.).

Table 8: Inductive bias como elección de $\mathcal{L}$.

Arquitectura	**$\mathcal{L}$ implícito**	**Efecto**
MLP genérico	I (identidad)	Sin reducción, M grande
CNN	Invariancia traslacional	Reduce M para señales con simetría espacial
Transformer	Atención a tokens relevantes	Reduce M para secuencias con dependencias lejanas
RBF + k	$d/dt + k$ (linealiz.)	Reduce M si el sistema es cuasi-lineal
Red preentrenada	ANN_1	Reduce M en lo que ANN_1 ya aprendió

Resultado

La homotopía hace explícito y cuantificable lo que las arquitecturas de deep learning hacen implícitamente. La cadena $\varepsilon \to M \to N$ aplica a todas, con K_2 reemplazado por la medida de complejidad residual después de restar lo que $\mathcal{L}$ ya sabe.

10 La matemática formal que le falta a la IA

La IA actual es una disciplina empírica disfrazada de matemática. Tiene:

- Teoremas de *existencia*: Cybenko (1989), Hornik (1991) — existe una red que aproxima.
- Cotas *asintóticas*: Barron (1993) — el error decrece como $O(1/\sqrt{M})$.
- Algoritmos que *funcionan*: backprop, Adam, SGD.

Pero **no tiene ecuaciones de diseño**. Un ingeniero eléctrico diseña un filtro: le dan la frecuencia de corte y calcula el orden. Un ingeniero civil diseña una viga: le dan la carga y calcula la sección. Un ingeniero de IA diseña una red: le dan el problema y... prueba. Neural Architecture Search. Hyperparameter sweep. Miles de millones de dólares en compute buscando arquitecturas a ciegas.

El framework homotópico provee la primera ecuación de diseño:

$$M \geq (b-a)\sqrt{\frac{C_\varphi\, K_2\,(e^{LT_f}-1)}{L\,\varepsilon_{\text{sim}}}}$$

Es una fórmula que un ingeniero puede computar con los datos del problema, **antes de entrenar**.

11 Síntesis: un solo framework para toda la IA

Toda la construcción se resume en una sola tabla:

Table 9: La ecuación de Liao aplicada a la inteligencia artificial.

Concepto IA	**Formalización homotópica**
Red neuronal	Operador no lineal $\mathcal{N}$
Entrenamiento	Deformación de $q=0$ a $q=1$
Learning rate	No existe. c_0 y λ autorregulan
Backpropagation	Caso degenerado: z_1 con $\lambda = 1/\eta$
Convergencia	$\lvert 1+\sigma\rvert < 1$, verificable
Inductive bias	Elección de $\mathcal{L}$
Dimensionamiento	$\varepsilon \to M \to N \to T$ (constructivo)
Conocimiento previo	$\mathcal{L}$ = modelo conocido $\to$ reduce M
Transfer learning	$\mathcal{L}$ = ANN preentrenada
Boosting / ResNets	Aprendizaje incremental con $\mathcal{L} = \sum \text{ANN}_i$
PINN	Física en loss (constraint). Homotopía: física en $\mathcal{L}$ (reducción)
Problema inverso	HAM con $\mathcal{N}$ = ANN surrogate

Resultado

La ecuación de deformación de Liao $(1-q)\mathcal{L}[\phi-\phi_0] = q\,c_0\mathcal{N}[\phi]$ es la **ecuación constitutiva faltante de la inteligencia artificial**. Unifica entrenamiento, simulación, dimensionamiento, conocimiento previo, aprendizaje incremental y problemas inversos en un solo marco matemático formal.

12 Conclusiones y líneas abiertas

1. Toda ANN es un operador no lineal. La ecuación de Liao aplica a todas.
2. Los coeficientes de la red se *determinan* por deformación, no se *optimizan* por búsqueda.
3. La cadena $\varepsilon_{\text{sim}} \to M \to N \to T$ es la primera ecuación de diseño para redes neuronales.
4. El conocimiento previo entra como $\mathcal{L}$ y reduce M cuantitativamente. Esto formaliza el inductive bias.
5. Cuando $\mathcal{L}$ es una ANN previa, emerge aprendizaje incremental convergente con redes progresivamente más chicas.
6. La ANN como sucedáneo de la física permite resolver problemas inversos por HAM sin modelo analítico.
7. Todo esto está conectado con PINN, boosting, ResNets, transfer learning — pero con fundamento formal y ecuaciones de diseño.

12.1 Líneas abiertas

- **Tasas de aproximación para Transformers.** La cadena (3) requiere la tasa $\varepsilon(M)$ para cada arquitectura. Para RBF y MLP existen (Wu–Schaback, Barron). Para Transformers, no. El framework indica dónde buscar: en la relación entre la complejidad de $\mathcal{N}$ y la curvatura del problema.
- **$\mathcal{L}$ adaptativo.** Usar la linealización de la RBF *en cada paso temporal* (no fija): $k = \hat{f}'(y_{k-1})$. Esto da $\lambda \approx 1$ siempre (bien condicionado).
- **Certificación para sistemas embebidos.** La cadena $\varepsilon \to M \to N$ es un argumento de certificación: "esta red con $M = 5$ centros garantiza error $< 5\%$ durante 10 segundos, con 20 datos de calibración."
- **Formalización como tesis.** Este apunte constituye el núcleo teórico de una posible tesis doctoral en la intersección de análisis funcional, teoría de la aproximación e inteligencia artificial.

"Poner la física en la función de costo es agregar una restricción.
Poner la física en el operador es reducir el problema."

San Juan, abril de 2026